

全域運動補償之指向性多目標追蹤

Referring Multi-Object Tracking aided by
Global Motion Compensation

指導教授：朱威達

專題成員：白昕宸、王駿愷、彭以呈

開發工具：Python、PyTorch、OpenCV

測試環境：Ubuntu 22.04、Refer-KITTI 資料集

一、簡介


在車載攝影機拍攝的影片中，畫面中物體的位移不一定代表物體本身正在移動，也可能源自攝影機的前進、轉向或晃動。如何區分物體的真實運動與相機自我運動（ego-motion），是動態場景理解與目標追蹤的核心問題；若無法有效分離兩者，系統便容易誤判物體的運動狀態，連帶影響追蹤與辨識結果。

此問題在**指向性多目標追蹤**（Referring Multi-Object Tracking, RMOT）中尤為明顯。RMOT 須在輸入影片與自然語言描述（如 *moving cars*、*turning vehicles*）後，從眾多追蹤目標中找出符合描述者；然而現有方法或仰賴視覺外觀特徵，或僅以原始邊界框位移作為運動線索，皆未補償相機的自我運動；當畫面位移混雜物體運動與相機運動時，模型便難以正確判斷涉及運動語意的描述。

為此，本研究提出 **GMC-Link**：透過**全域運動補償**（Global Motion Compensation, GMC）預估相機運動，萃取物體的真實殘餘運動資訊，與語言特徵對齊後，融合至既有 RMOT 模型輸出，藉以強化對運動語意描述的辨識能力。

- **全域運動補償（GMC）**：以 ORB 特徵點搭配 BFMatcher（Hamming + Lowe's ratio 0.7）比對，經 RANSAC 估計**單應性矩陣**（homography）建立相鄰影格間的背景對映，並以前景遮罩避免誤抓物件特徵，確保補償的是相機而非物體運動。
- **累積單應性與多尺度殘餘速度**：保存物件原始未變形中心座標，以累積複合單應性一次性校正，計算三個時間尺度（gap = 2, 5, 10 影格）的殘餘速度（原始速度 - 相機速度），輸出含多尺度位移、寬高變化、中心座標、尺寸與訊噪比的 **13 維運動向量**。
- **運動-語言對齊**：採**共享權重**（shared-weight）雙塔架構，運動 13D 與語言 384D 各經 Linear adapter 投影至 256D，再通過共享 MLP 主幹並 L2 正規化；以對稱式 InfoNCE Loss 訓練，推論時直接輸出原始**餘弦相似度**（cosine similarity）。
- **決策層線性加成融合**：以 $\text{final} = \text{model_logit} + \alpha \cdot (\text{sc} \cdot \text{raw_cos} + \text{thr})$ 將 GMC 運動分數加成至原模型輸出，依運動／外觀兩軸分別校準後送入 HOTA 評估，判定是否匹配。

語言端以 SentenceTransformer（all-MiniLM-L6-v2，384D）編碼描述句。整體系統架構如圖一所示。



(圖一) GMC-Link 系統架構圖

二、測試結果

本研究於 Refer-KITTI 資料集上，對三種基礎追蹤架構進行交叉驗證，採 $n = 3$ 多隨機種子、以 pooled HOTA 為指標評估融合前後表現。由表一可見，GMC-Link 在 3 個架構中有 2 個超越原論文，且增益穩定：

架構·資料集	原模型	+ GMC-Link	原論文	較原論文
iKUN · V1	44.224	44.634	44.564	+0.070
FlexHook · V1	53.110	53.526	53.824	-0.298
FlexHook · V2	42.526	42.807	42.526	+0.281

(表一) 融合前後 pooled HOTA 比較。

GMC-Link 的增益主要來自運動類別描述（如「moving cars」「turning vehicles」）——這正是純外觀模型最弱、也是本系統設計初衷所在。以 iKUN · V1 為例，原模型於運動描述上 HOTA 僅 25.531，遠低於靜止描述的 43.914，落差近 18 分；加入 GMC-Link 後提升至 30.093 (+4.562)，大幅彌平此落差。三種架構在運動描述上皆獲提升（見表二）：

架構·資料集	原模型	+ GMC-Link	增益
iKUN · V1	25.531	30.093	+4.562
FlexHook · V1	43.981	45.785	+1.804
FlexHook · V2	48.018	48.758	+0.740

(表二) 僅運動類別描述之 pooled HOTA 增益。

此結果印證全域運動補償為運動語意判斷的關鍵：相較直接採用原始邊界框位移的方法，ORB 加單應性的幾何補償能有效分離相機運動，是運動類別描述能否正確匹配的決定性元件。進一步分析顯示，多尺度時序速度（同時捕捉短／中／長期運動模式）為對齊分離度貢獻最大的單一設計；訊噪比特徵雖未提升平均分離度，卻顯著降低了預測變異。

整體而言，本系統以決策層加成方式接入，不更動亦不重訓基礎模型，可泛化至多種對空間運動不敏感（spatially-ignorant）的視覺-語言追蹤框架；並透過逐類別 GMC 關聯性調節（運動軸與外觀軸採不同校準尺度），抑制運動訊號於純外觀描述（如「black cars」）上的雜訊干擾，達成從感知、對齊、融合到判定的完整增強流程。